Classificação de Grãos de Feijão Seco com MLP Treinada por Backpropagation

Autores: Pedro Otávio e Gabriel Marques
Versão: 1.1.0 — V1.0.0 + Apêndice B (Q2b)
Projeto: `mlp-dry-bean-backprop`
Data: 06/11/2026
Ambiente: Python 3.11.15; TensorFlow 2.15.1 (CPU); NumPy 1.26.4; Pandas 2.1.4; Scikit-learn 1.3.2; 16 vCPUs; 6,6 GB de RAM; sem GPU.
Código: `notebooks/01_experimentos.ipynb` e `notebooks/02_analise_resultados.ipynb`.
Resultados: `results/csv/`, `results/figures/` e `results/tables/`.

> Todos os valores deste relatório foram obtidos dos CSVs gerados pela execução dos notebooks. Nenhum resultado foi inventado.

1. Introdução e contextualização

A classificação automática de variedades de grãos é um problema multiclasse com classes parcialmente sobrepostas no espaço de atributos. Este trabalho utiliza o Dry Bean Dataset, composto por 13.611 instâncias descritas por 16 atributos numéricos contínuos extraídos de imagens, distribuídas em 7 classes: Seker, Barbunya, Bombay, Cali, Dermason, Horoz e Sira.

O dataset foi obtido do UCI (ID 602) e convertido do ARFF original para CSV, preservando as 16 features e o rótulo `Class`. O modelo adotado é uma Multilayer Perceptron (MLP) treinada por Backpropagation, com ReLU nas camadas ocultas e Softmax na saída. O estudo segue sete etapas: inicialização de pesos (Q1), learning rate e momento (Q2), topologia (Q3), quantidade de dados (Q4), atributos (Q5), avaliação final no teste (Q6) e validação cruzada (Q7).

2. Dataset e metodologia

A distribuição das classes é desbalanceada, como mostra a Tabela 1. Dermason concentra 3.546 exemplos, enquanto Bombay possui 522. Por isso, a métrica principal é o macro-F1, que pondera igualmente as classes; a acurácia e o weighted-F1 são reportados como complementares.

class	count
Dermason	3546
Sira	2636
Seker	2027
Horoz	1928
Cali	1630
Barbunya	1322
Bombay	522

Split. Foi adotado split externo estratificado de 70% desenvolvimento e 30% teste (seed 42). O desenvolvimento foi dividido em 80% treino e 20% validação, resultando em 56% treino, 14% validação e 30% teste. A Q1 usa apenas o treino de 56%; Q2–Q5 usam treino/validação; a Q6 treina nos 70% de desenvolvimento e avalia no teste de 30%; a Q7 faz validação cruzada k=5 no desenvolvimento de 70%, mantendo o teste intocado.

Pré-processamento. As classes foram codificadas em one-hot. O `StandardScaler` (Z-score) foi ajustado exclusivamente no treinamento correspondente e aplicado à validação/teste; a escolha do Z-score se deve à presença de atributos com escalas muito distintas e valores extremos, situação em que o Min-Max é mais sensível. Nas frações da Q4, o scaler foi reajustado no subconjunto de treino. Na Q5, a seleção de atributos usou somente o treino. Na Q7, scaler e regra de atributos foram reajustados dentro de cada fold.

Modelo. MLP com ativação ReLU nas camadas ocultas, inicialização Glorot uniform, saída Softmax com 7 neurônios, perda de entropia cruzada categórica, SGD com momento e batch size 32. Não foram usados dropout, regularização, class weights ou early stopping na validação. O critério de convergência foi loss de treino ≤ 0,001. A Q1 usou 100 épocas fixas; Q2–Q7 usaram no máximo 150 épocas. No protocolo principal, nenhuma configuração atingiu o limiar de 0,001; um experimento suplementar posterior (Apêndice B) atingiu o critério com 3×256 em 408 épocas, mas com pior generalização.

Métricas. Loss, acurácia, macro-F1, weighted-F1, precisão/revocação macro, tempo de treinamento, épocas e número de parâmetros. As regras de seleção foram definidas antes dos experimentos e aplicadas sem ajuste após os resultados.

3. Configurações experimentais

Item	Decisão
Split externo	70% desenvolvimento / 30% teste, estratificado, seed 42
Split interno	80% treino / 20% validação do desenvolvimento (56/14/30 efetivo)
Q1	16-60-7; ReLU/Softmax; SGD lr=0,01, momento=0,9; 100 épocas; seeds 42–46
Q2	lr {0,01; 0,1; 0,5} × momento {0,5; 0,7; 0,9}; 9 combinações; máximo 150 épocas
Q3	1–3 camadas; 10–100 neurônios, passo 10; largura uniforme; 30 configurações
Q4	20%, 40%, 60%, 80%, 100% do treino de 56%; amostragem estratificada
Q5	`all_16`, `low_redundancy` (

Item	Decisão
Q6	Top 4 da Q3 + Q2 + regra de atributos da Q5; treino 70%, teste 30%
Q7	k=5 estratificado no desenvolvimento de 70%; scaler/seletor dentro de cada fold
Batch size	32
Perda	Entropia cruzada categórica
Otimizador	SGD com momento (`nesterov=False`)
Critério de parada	Loss de treino ≤ 0,001; máximo de 150 épocas
Seeds	Q1 42–46; Q2–Q6 42; Q7 folds com seed 42

O tempo total de treinamento registrado foi de aproximadamente 116 minutos, dos quais cerca de 80 minutos correspondem à Q3. Os tempos por execução estão nos CSVs.

4. Resultados e discussão — Q1

Configuração. Topologia 16-60-7, ReLU/Softmax, SGD lr=0,01 e momento=0,9, 100 épocas, cinco seeds e somente o conjunto de treino (7.621 exemplos).

seed	loss_final	accuracy_final	macro_f1_final	time_s
42.0000	0.1620	0.9436	0.9527	31.6624
43.0000	0.1616	0.9437	0.9532	33.0142
44.0000	0.1592	0.9424	0.9523	53.7355
45.0000	0.1612	0.9429	0.9523	48.7645
46.0000	0.1597	0.9431	0.9518	51.2766

Análise. As cinco inicializações produziram resultados muito próximos: loss final média 0.1607 ± 0.0012, acurácia final 0.9431 ± 0.0005 e macro-F1 final 0.9525 ± 0.0005. A dispersão é baixa, indicando que a arquitetura é pouco sensível à inicialização dentro das seeds testadas. As curvas de loss e acurácia (Figuras 1 e 2) mostram convergência suave, sem divergência ou estagnação evidente.

Como apenas o treino foi utilizado, não é possível confirmar overfitting; a loss continuou caindo lentamente e a acurácia se aproximou de 94,3%. A topologia e as ativações escolhidas se mostraram adequadas para servir de base à Q2.

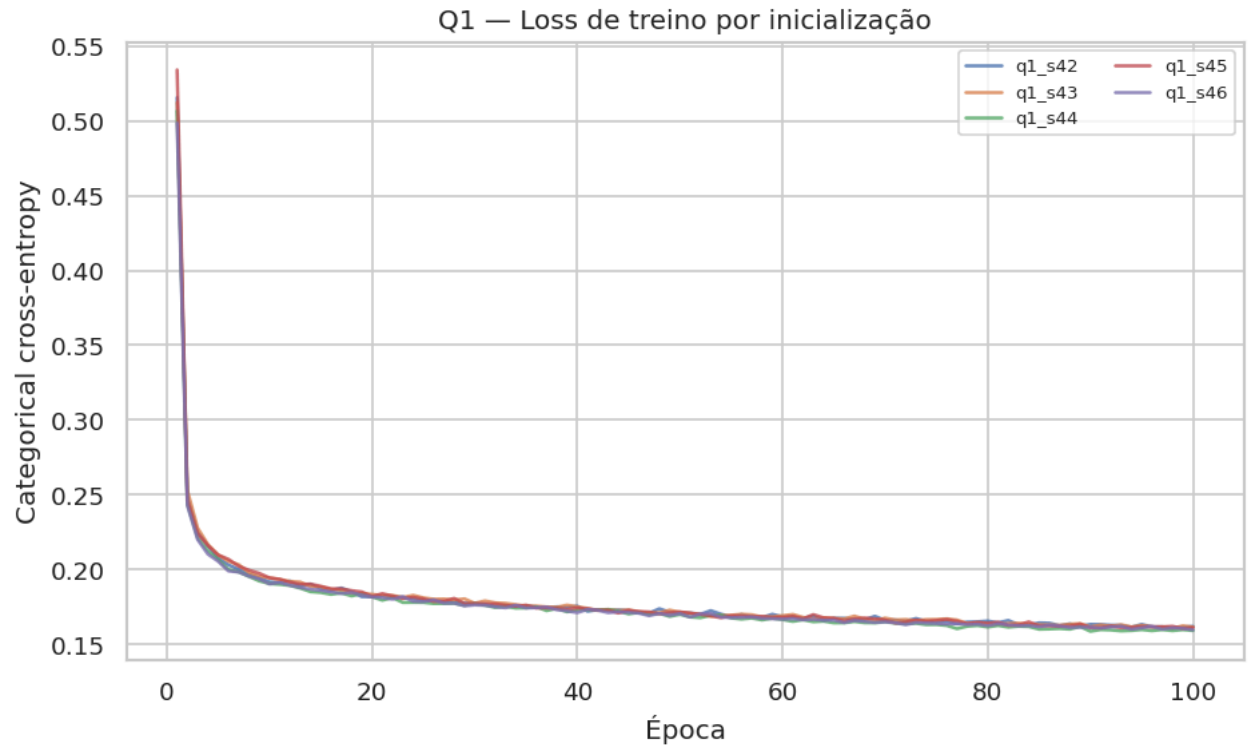


Figura 1 — Loss de treino por inicialização (Q1).

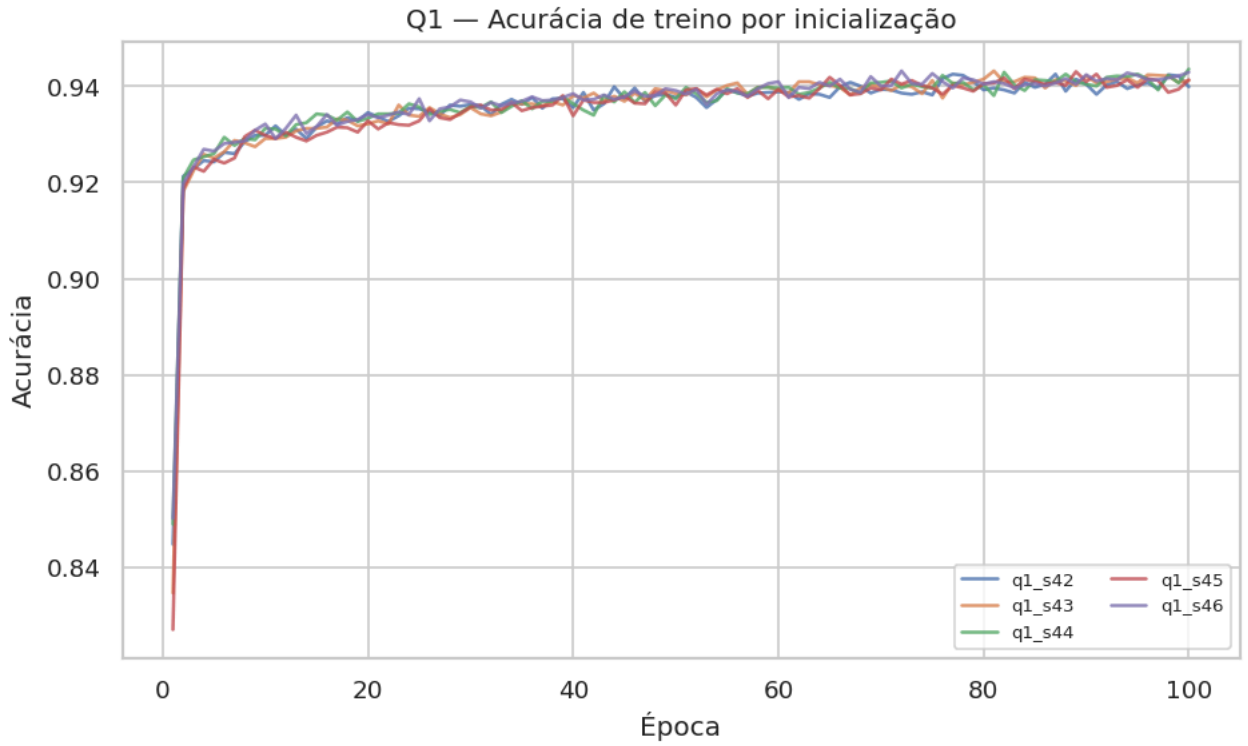


Figura 2 — Acurácia de treino por inicialização (Q1).

Conclusão da Q1. O modelo aprende padrões básicos de forma estável; a inicialização não foi um fator crítico. A topologia 16-60-7 foi mantida na Q2.

5. Resultados e discussão — Q2

Configuração. Nove combinações de learning rate e momento, mantendo a topologia da Q1, treino/validação e máximo de 150 épocas.

run_id	learning_rate	momentum	loss_train	acc_train	loss_val	acc_val	macro_f1_val	time_s	selected
q2_lr0.01_m0.9	0.0100	0.9000	0.1524	0.9448	0.1934	0.9334	0.9477	90.4728	True
q2_lr0.01_m0.5	0.0100	0.5000	0.1705	0.9386	0.1997	0.9318	0.9445	124.4249	False
q2_lr0.01_m0.7	0.0100	0.7000	0.1648	0.9398	0.1978	0.9313	0.9442	104.5845	False
q2_lr0.1_m0.5	0.1000	0.5000	0.1459	0.9462	0.1943	0.9286	0.9419	105.5240	False
q2_lr0.1_m0.7	0.1000	0.7000	0.1456	0.9461	0.2081	0.9255	0.9400	112.2521	False
q2_lr0.5_m0.5	0.5000	0.5000	0.1738	0.9402	0.2649	0.9271	0.9394	113.9530	False
q2_lr0.1_m0.9	0.1000	0.9000	0.1656	0.9392	0.2588	0.9239	0.9388	103.0194	False
q2_lr0.5_m0.7	0.5000	0.7000	0.2089	0.9339	0.3099	0.9176	0.9313	108.8195	False
q2_lr0.5_m0.9	0.5000	0.9000	1.6892	0.2988	1.7168	0.2980	0.2027	91.7031	False

Análise. A melhor combinação foi **lr=0,01 e momento=0,9**, com macro-F1 de validação 0.9477, loss de validação 0.1934 e acurácia de validação 0.9334. Taxas de 0,01 e 0,1 apresentaram comportamento estável; lr=0,5 com momento=0,9 degradou fortemente o aprendizado (loss de treino 1.6892, macro-F1 0.2027), evidenciando instabilidade com taxa alta e momento alto.

Nenhuma das nove configurações atingiu a loss de treino de 0,001 em 150 épocas; todas foram registradas como `converged=False`. A seleção seguiu a regra de fallback: melhor macro-F1 de validação entre as execuções válidas. O heatmap de macro-F1 (Figura 3) e as curvas de loss (Figura 4) mostram que o ganho de desempenho se concentra em taxas menores, com 0,01 e 0,1 próximas.

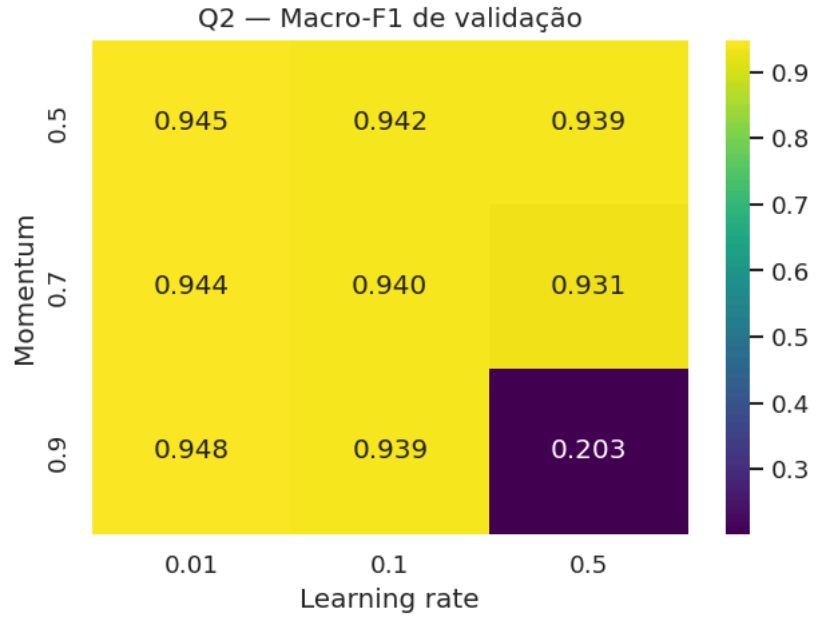


Figura 3 — Macro-F1 de validação por learning rate e momento (Q2).

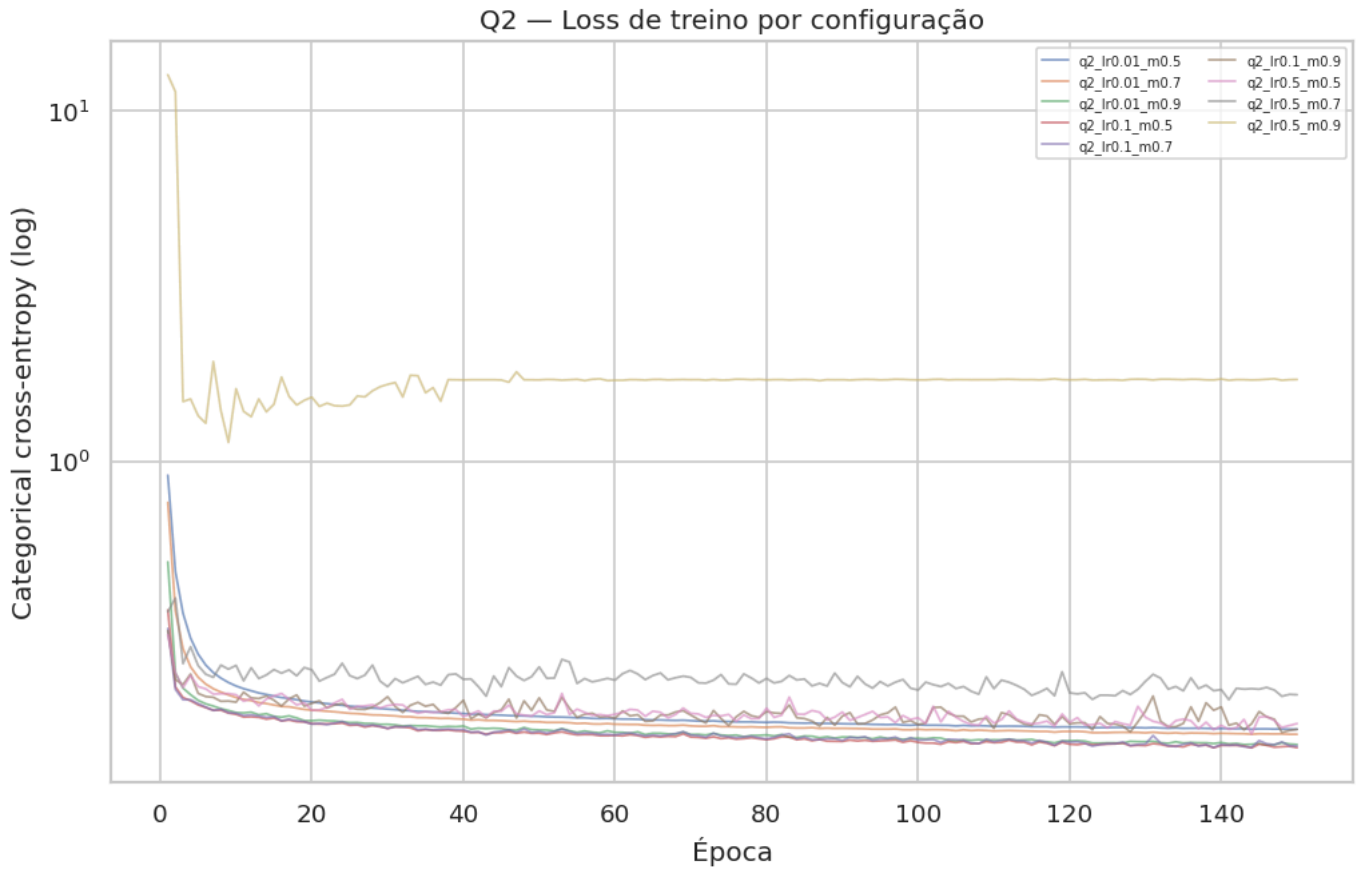


Figura 4 — Curvas de loss por configuração (Q2).

Conclusão da Q2. A combinação lr=0,01 e momento=0,9 ofereceu o melhor equilíbrio entre estabilidade e macro-F1 de validação e foi adotada na Q3–Q7.

6. Resultados e discussão — Q3

Configuração. Trinta topologias (1–3 camadas ocultas; 10–100 neurônios em passos de 10, largura uniforme), com lr=0,01 e momento=0,9, treino/validação e máximo de 150 épocas.

Resumo por profundidade.

n_layers	macro_mean	loss_mean	time_mean
1.0000	0.9455	0.1933	133.7674
2.0000	0.9418	0.2027	160.1876

n_layers	macro_mean	loss_mean	time_mean
3.0000	0.9387	0.2454	184.3658

Tabela completa das 30 topologias.

rank	n_layers	neurons	n_params	loss_train	loss_val	macro_f1_val	time_s	selected_top4
1	1	60	1447	0.1524	0.1934	0.9477	154.1231	True
2	1	100	2407	0.1482	0.1924	0.9473	143.5863	True
3	1	40	967	0.1564	0.1875	0.9471	107.4950	True
4	1	90	2167	0.1511	0.1906	0.9470	126.2830	True
5	1	20	487	0.1667	0.1978	0.9457	154.0960	False
6	1	50	1207	0.1543	0.1892	0.9457	142.0662	False
7	2	10	357	0.1759	0.1972	0.9447	116.5399	False
8	1	70	1687	0.1513	0.1881	0.9446	126.4709	False
9	1	80	1927	0.1497	0.1944	0.9436	136.5083	False
10	2	100	12507	0.1108	0.2056	0.9435	218.9292	False
11	2	70	6657	0.1218	0.2018	0.9433	101.4758	False
12	1	30	727	0.1595	0.1963	0.9431	139.5826	False
13	1	10	247	0.1764	0.2030	0.9431	107.4624	False
14	2	50	3757	0.1190	0.2032	0.9426	166.8196	False
15	2	40	2607	0.1247	0.2000	0.9423	156.8920	False
16	2	90	10357	0.1163	0.2048	0.9423	212.6684	False
17	3	100	22607	0.0792	0.2643	0.9416	164.6802	False
18	2	60	5107	0.1193	0.1967	0.9409	130.6833	False
19	3	20	1327	0.1412	0.2091	0.9407	192.1041	False
20	3	10	467	0.1707	0.2095	0.9407	189.6106	False
21	2	20	907	0.1556	0.2047	0.9402	131.1196	False
22	3	50	6307	0.0947	0.2490	0.9402	161.3903	False
23	3	80	14887	0.0704	0.2583	0.9402	188.7607	False
24	3	30	2587	0.1128	0.2281	0.9396	228.0655	False
25	2	30	1657	0.1361	0.2013	0.9394	166.2092	False
26	2	80	8407	0.1156	0.2120	0.9390	200.5385	False
27	3	90	18547	0.0759	0.2639	0.9368	164.5245	False
28	3	40	4247	0.1011	0.2347	0.9361	178.0491	False
29	3	60	8767	0.0777	0.2728	0.9359	154.8936	False
30	3	70	11627	0.0777	0.2645	0.9356	221.5794	False

Quatro melhores topologias.

rank	run_id	n_layers	neurons	n_params	loss_val	macro_f1_val	time_s
1	q3_l1_n60_s42	1	60	1447	0.1934	0.9477	154.1231
2	q3_l1_n100_s42	1	100	2407	0.1924	0.9473	143.5863
3	q3_l1_n40_s42	1	40	967	0.1875	0.9471	107.4950
4	q3_l1_n90_s42	1	90	2167	0.1906	0.9470	126.2830

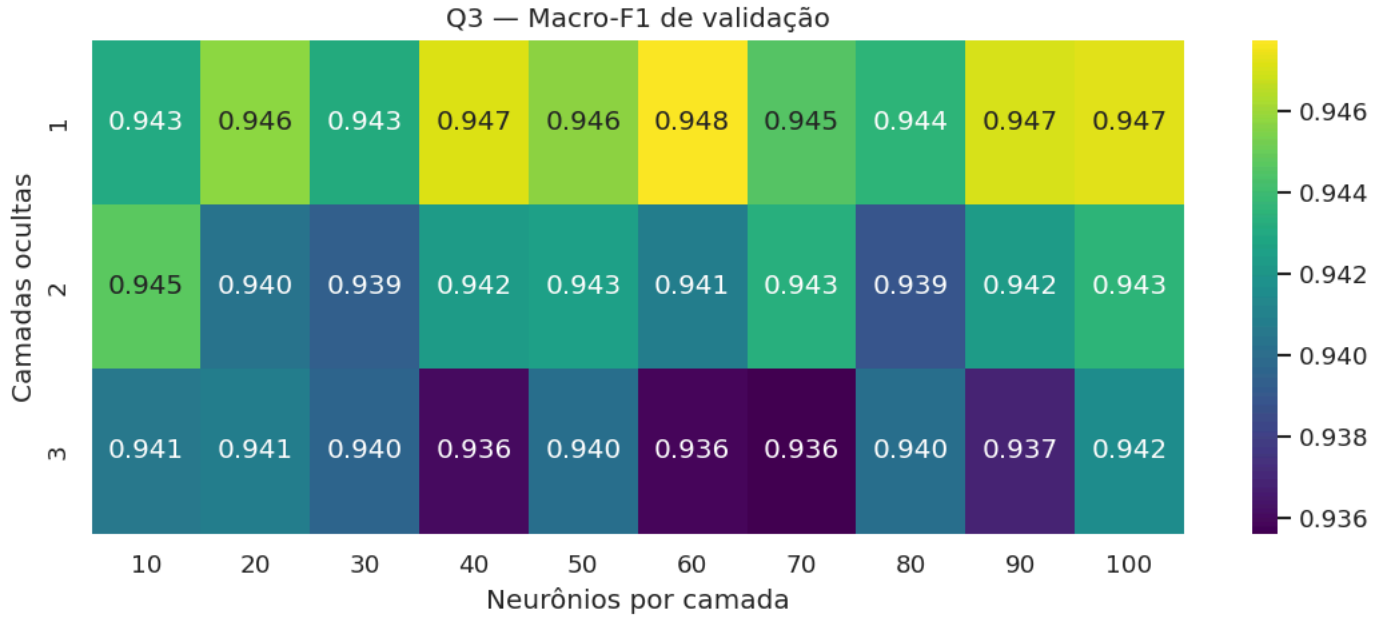


Figura 5 — Macro-F1 de validação por topologia (Q3).

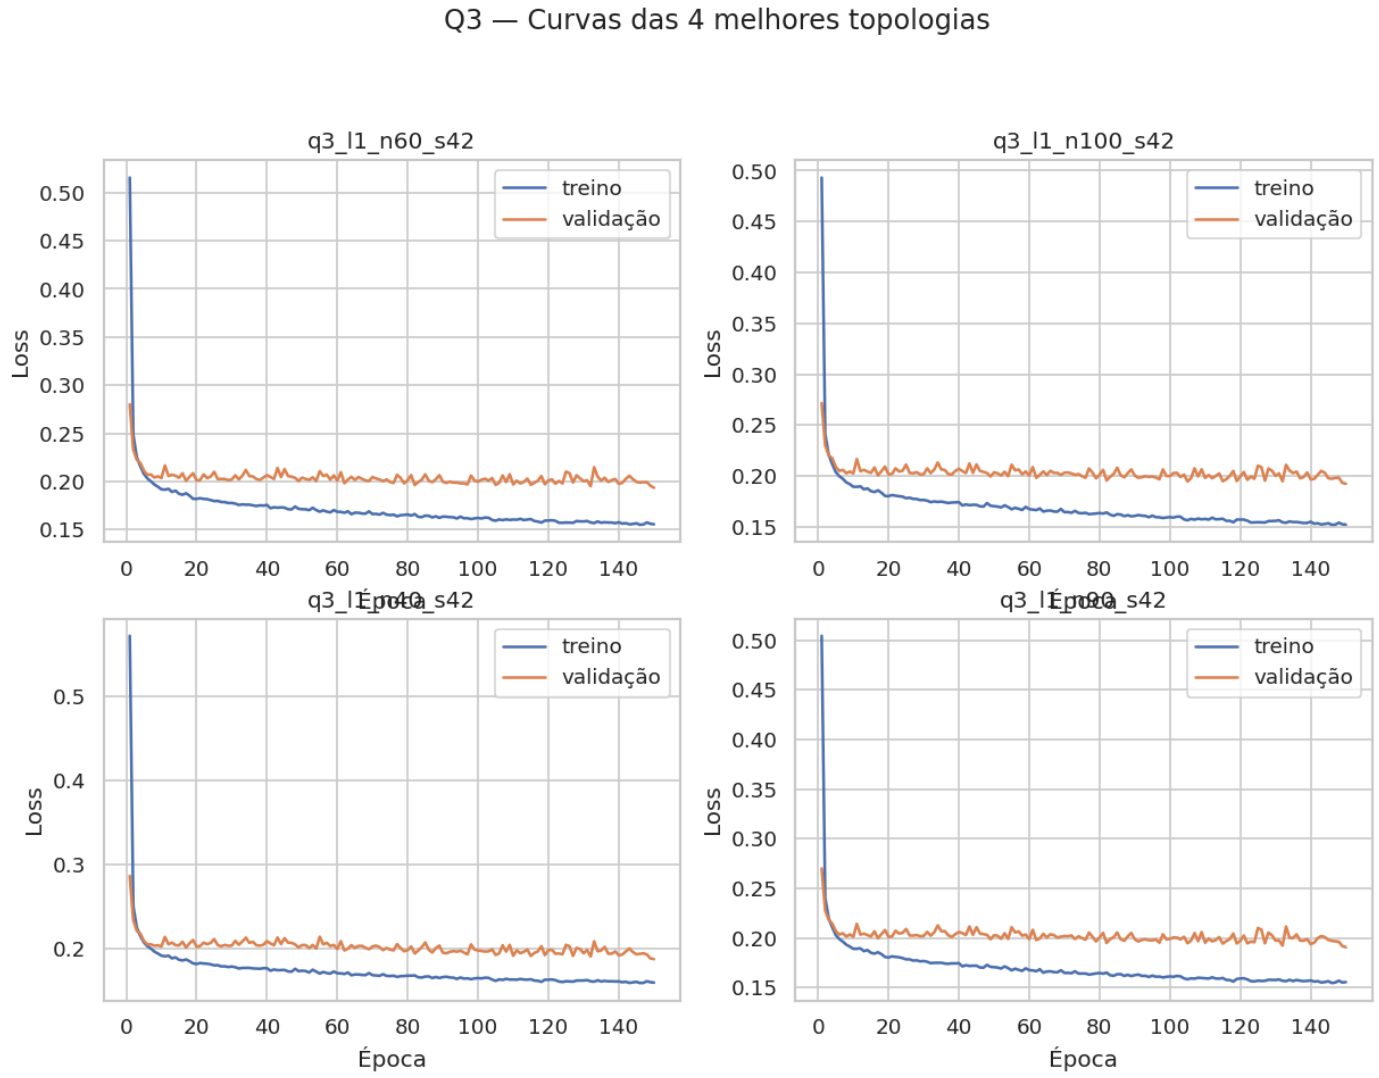


Figura 6 — Curvas das quatro melhores topologias (Q3).

Análise. Redes com uma única camada oculta tiveram o melhor desempenho médio (macro-F1 médio 0.9455); duas e três camadas apresentaram médias de 0.9418 e 0.9387, respectivamente. O aumento de profundidade também elevou o tempo médio de 133.8s para 184.4s e a loss de validação, sugerindo maior dificuldade de otimização e/ou overfitting.

As quatro melhores foram todas de uma camada oculta: 60, 100, 40 e 90 neurônios. A melhor foi 1×60 (macro-F1 0.9477); a 1×100 ficou muito próxima (0.9473) e foi posteriormente vencedora na Q6.

Conclusão da Q3. A complexidade adicional não trouxe ganho de generalização. As topologias 1×60, 1×100, 1×40 e 1×90 seguiram para a Q6.

7. Resultados e discussão — Q4

Configuração. Melhor configuração da Q3 (1×60), todos os 16 atributos, frações de 20–100% do treino de 56%, amostragem estratificada, scaler no subconjunto e validação fixa.

fraction	n_train	loss_train	acc_train	loss_val	acc_val	macro_f1_val	time_s	selected
0.2000	1524	0.1521	0.9495	0.2301	0.9307	0.9429	20.9326	False
0.4000	3048	0.1556	0.9406	0.2166	0.9255	0.9404	28.1193	False
0.6000	4572	0.1506	0.9451	0.2106	0.9297	0.9432	34.1574	False
0.8000	6096	0.1543	0.9447	0.2079	0.9297	0.9431	45.7460	False
1.0000	7621	0.1524	0.9448	0.1934	0.9334	0.9477	51.2518	True

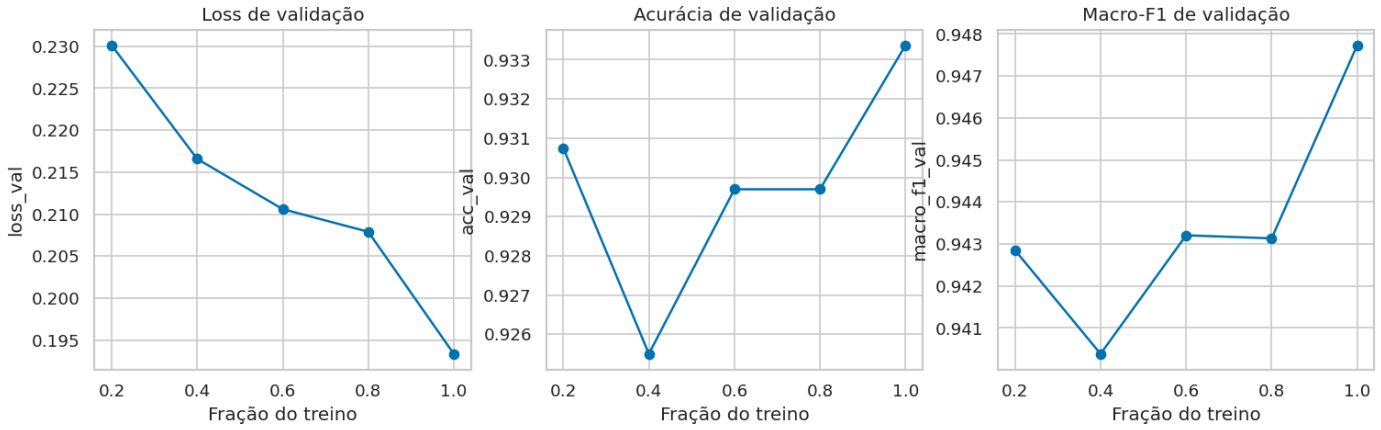


Figura 7 — Curvas de generalização por fração de treino (Q4).

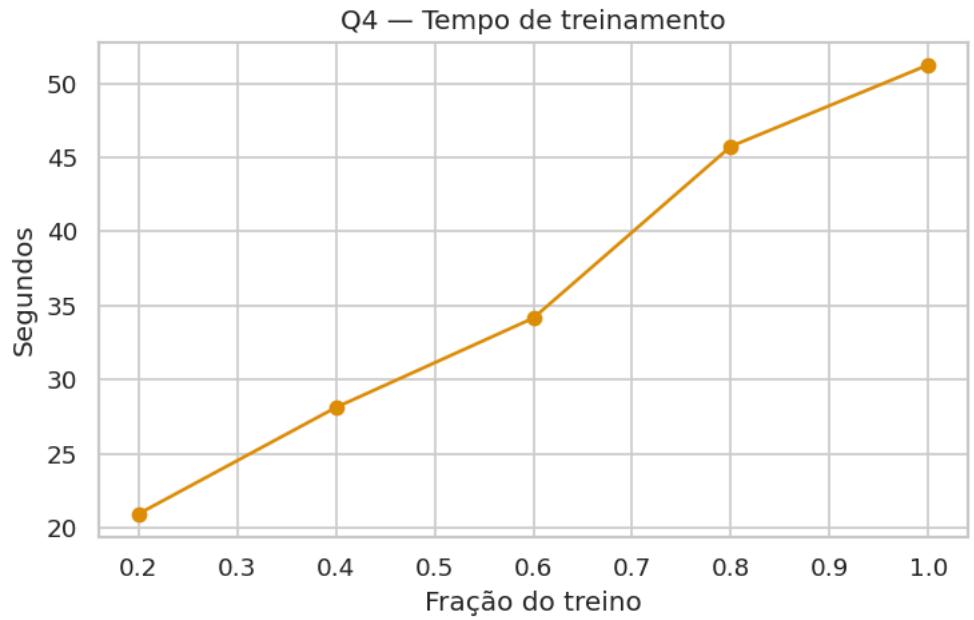


Figura 8 — Tempo de treinamento por fração (Q4).

Análise. O desempenho de validação melhorou de forma geral com o aumento dos dados: a macro-F1 foi 0.9429 com 20% e 0.9477 com 100%; a loss de validação caiu de 0.2301 para 0.1934. O tempo de treinamento cresceu de 20.9s para 51.3s. A fração de 40% apresentou um resultado ligeiramente inferior ao de 20%, indicando ruído de amostragem com uma única seed; a tendência global, porém, é de melhora com mais dados.

Conclusão da Q4. Mais dados melhoraram a generalização, com retorno decrescente. A fração de 100% foi selecionada e o modelo final da Q6 usou todo o desenvolvimento de 70%.

8. Resultados e discussão — Q5

Configuração. Melhor configuração da Q3 + hiperparâmetros da Q2; treino/validação de 56%/14%. A informação mútua, a variância e a correlação foram calculadas somente no treino. A regra `low_redundancy` remove, em cada componente de correlação ≥ 0,95, o atributo de menor MI.

Atributos e relevância.

feature	variance	mutual_info	low_redundancy	top_10_mi	compact	no_noise
Perimeter	45407.71484	1.06276	True	True	True	True
EquivDiameter	3459.93848	1.03731	False	True	False	True
ConvexArea	871674560.00000	1.03600	False	True	False	True
Area	845741504.00000	1.03600	False	True	False	True
MajorAxisLength	7272.54248	0.99203	False	True	False	True
ShapeFactor2	0.00000	0.95457	True	True	True	True
MinorAxisLength	1996.55688	0.93145	False	True	False	True
ShapeFactor1	0.00000	0.92642	True	True	True	True
ShapeFactor3	0.00976	0.82443	True	True	True	True
Compactness	0.00380	0.82442	False	True	False	True
AspectRatio	0.06099	0.81673	False	False	False	True
Eccentricity	0.00838	0.81667	False	False	False	True
Roundness	0.00355	0.79726	True	False	True	True
ShapeFactor4	0.00002	0.34984	True	False	True	True
Solidity	0.00002	0.24288	True	False	True	True
Extent	0.00240	0.20330	True	False	True	True

Subconjuntos comparados.

subset	n_features	loss_train	acc_train	loss_val	acc_val	macro_f1_val	time_s	selected
low_redundancy	8	0.1522	0.9438	0.1871	0.9307	0.9452	50.8499	True
all_16	16	0.1524	0.9448	0.1934	0.9334	0.9477	51.3290	False
no_noise	16	0.1524	0.9448	0.1934	0.9334	0.9477	0.0000	False
compact	8	0.1522	0.9438	0.1871	0.9307	0.9452	54.8343	False
top_10_mi	10	0.2187	0.9171	0.2349	0.9098	0.9235	51.7245	False

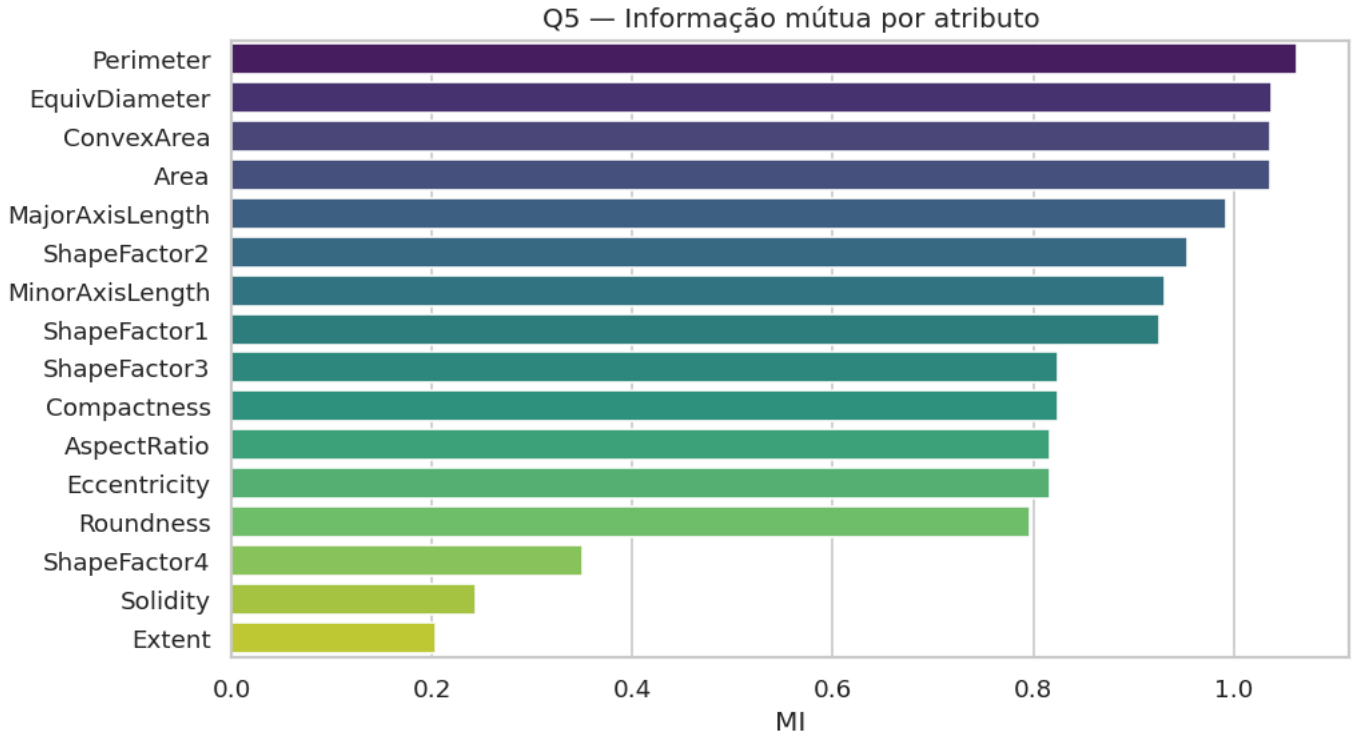


Figura 9 — Ranking de informação mútua (Q5).

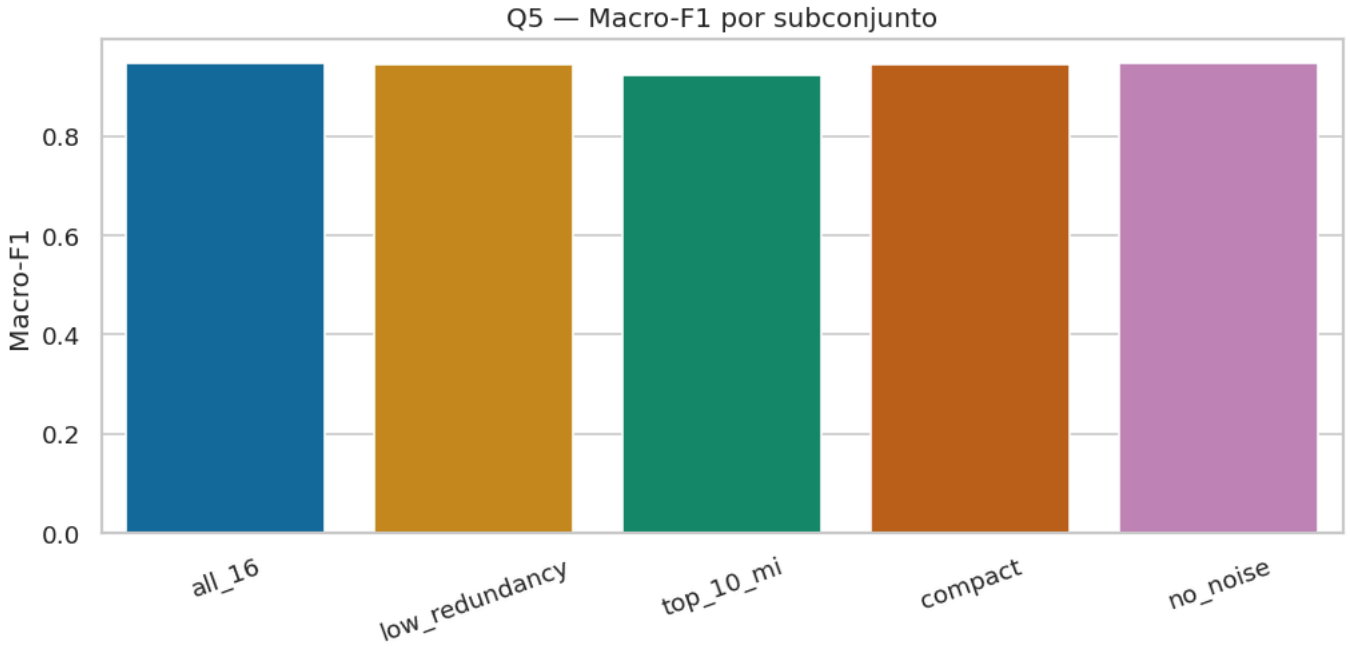


Figura 10 — Comparação dos subconjuntos (Q5).

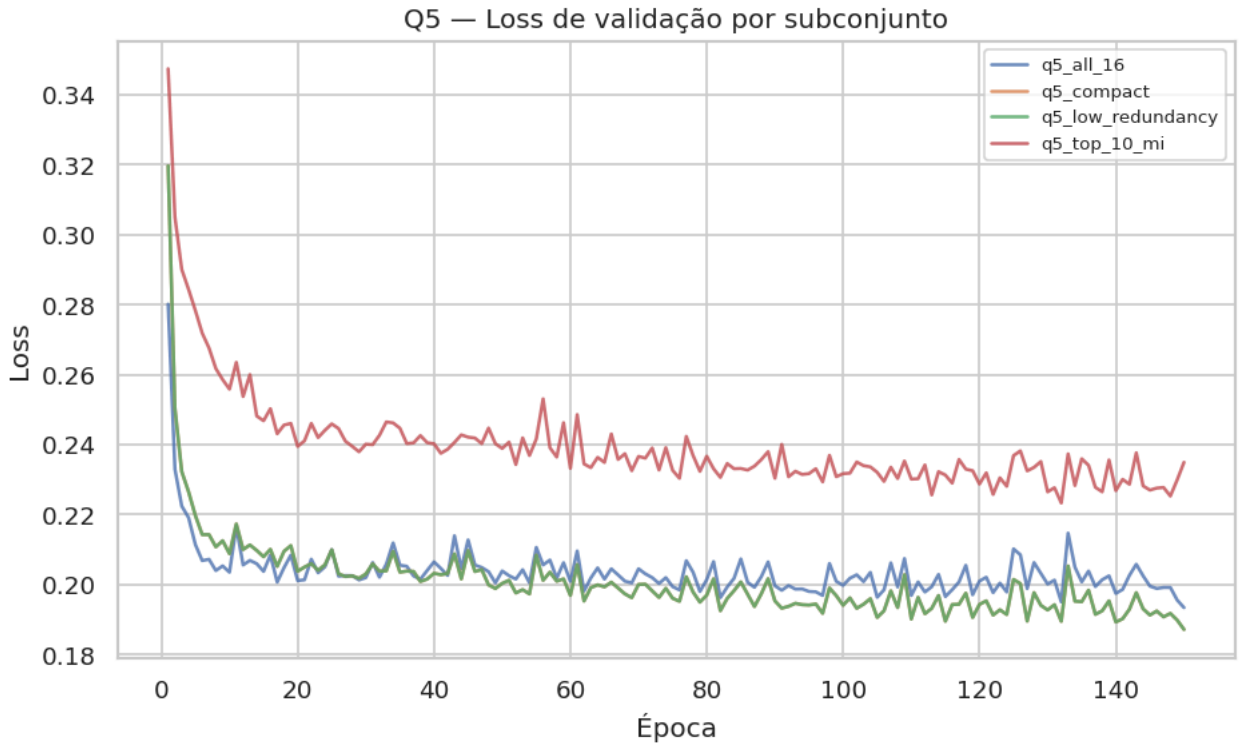


Figura 11 — Loss de validação por subconjunto (Q5).

Análise. Os atributos de maior informação mútua foram Perimeter (1.0628), EquivDiameter (1.0373), ConvexArea (1.0360) e Area (1.0360). Os menores valores ficaram com Extent (0.2033), Solidity (0.2429) e ShapeFactor4 (0.3498).

O conjunto completo obteve macro-F1 0.9477; o subconjunto `low_redundancy`, com 8 atributos (Perimeter, Extent, Solidity, Roundness, ShapeFactor1, ShapeFactor2, ShapeFactor3, ShapeFactor4), obteve 0.9452, dentro da tolerância de 0,005 e com menos atributos, sendo selecionado pela regra de parcimônia. Os atributos removidos por redundância foram: EquivDiameter, ConvexArea, Area, MajorAxisLength, MinorAxisLength, Compactness, AspectRatio, Eccentricity. O `top_10_mi` foi pior (0.9235), possivelmente por manter atributos altamente correlacionados. A regra de ruído não removeu nenhum atributo, e o subconjunto `no_noise` foi equivalente ao conjunto completo.

Conclusão da Q5. A remoção de redundância reduziu a dimensionalidade de 16 para 8 sem perda relevante de macro-F1. A regra `low_redundancy` foi adotada na Q6 e reajustada em cada fold da Q7.

9. Resultados e discussão — Q6

Configuração. Quatro topologias da Q3, hiperparâmetros da Q2 (lr=0,01, momento=0,9), regra `low_redundancy` reajustada no desenvolvimento de 70%, treino no desenvolvimento e avaliação no teste de 30% (4.084 exemplos), máximo de 150 épocas. As curvas de teste foram registradas por callback apenas para visualização; a parada usou exclusivamente a loss de treino.

run_id	n_layers	neurons	n_params	loss_train	acc_train	macro_f1_train	loss_test	acc_test	macro_f1_test	weighted_f1_test	tim
q6_q3_l1_n100_s42	1	100	1607	0.1493	0.9448	0.9542	0.1963	0.9280	0.9402	0.9280	83.
q6_q3_l1_n40_s42	1	40	647	0.1564	0.9417	0.9516	0.1955	0.9283	0.9401	0.9283	83.
q6_q3_l1_n90_s42	1	90	1447	0.1491	0.9446	0.9544	0.1973	0.9275	0.9396	0.9275	83.
q6_q3_l1_n60_s42	1	60	967	0.1516	0.9444	0.9543	0.1975	0.9270	0.9395	0.9270	78.

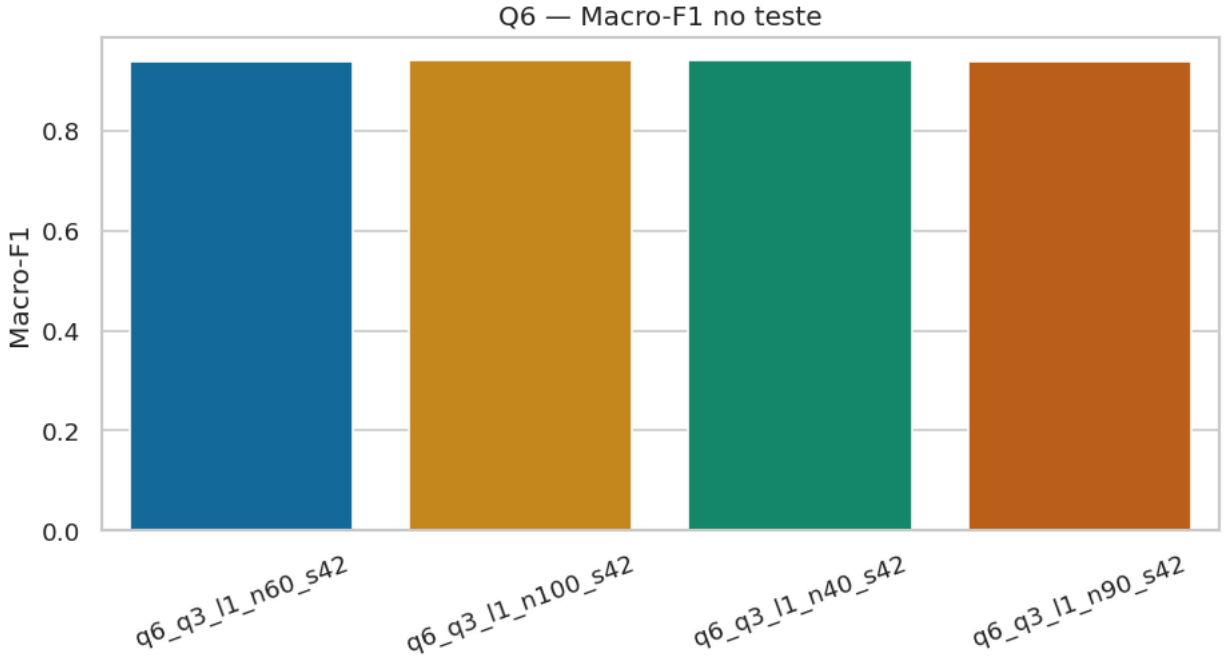


Figura 12 — Macro-F1 no teste (Q6).

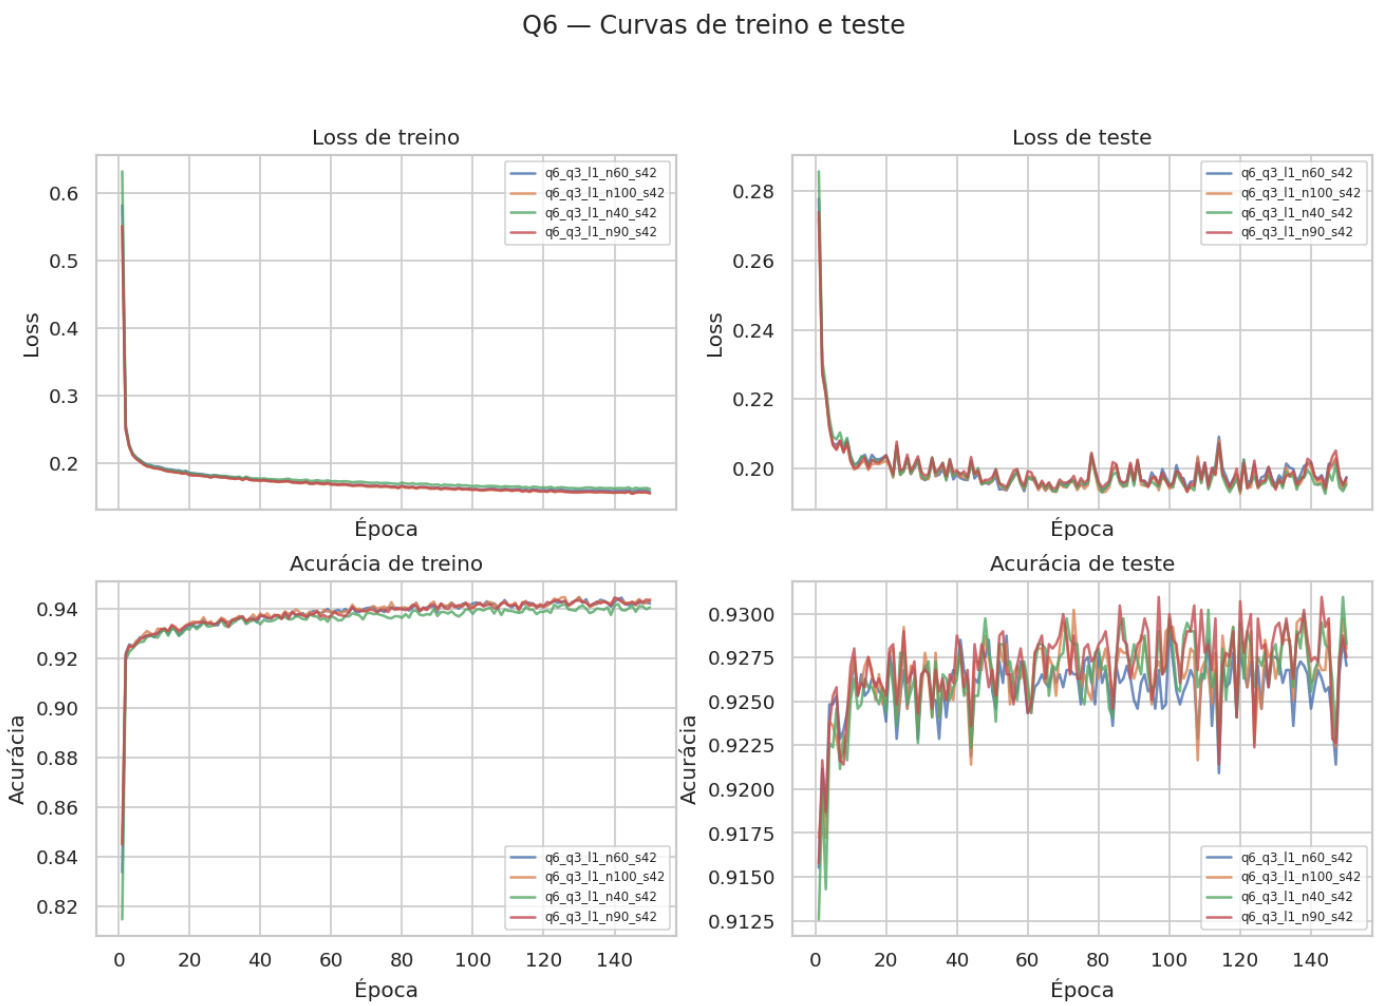


Figura 13 — Curvas de treino e teste (Q6).

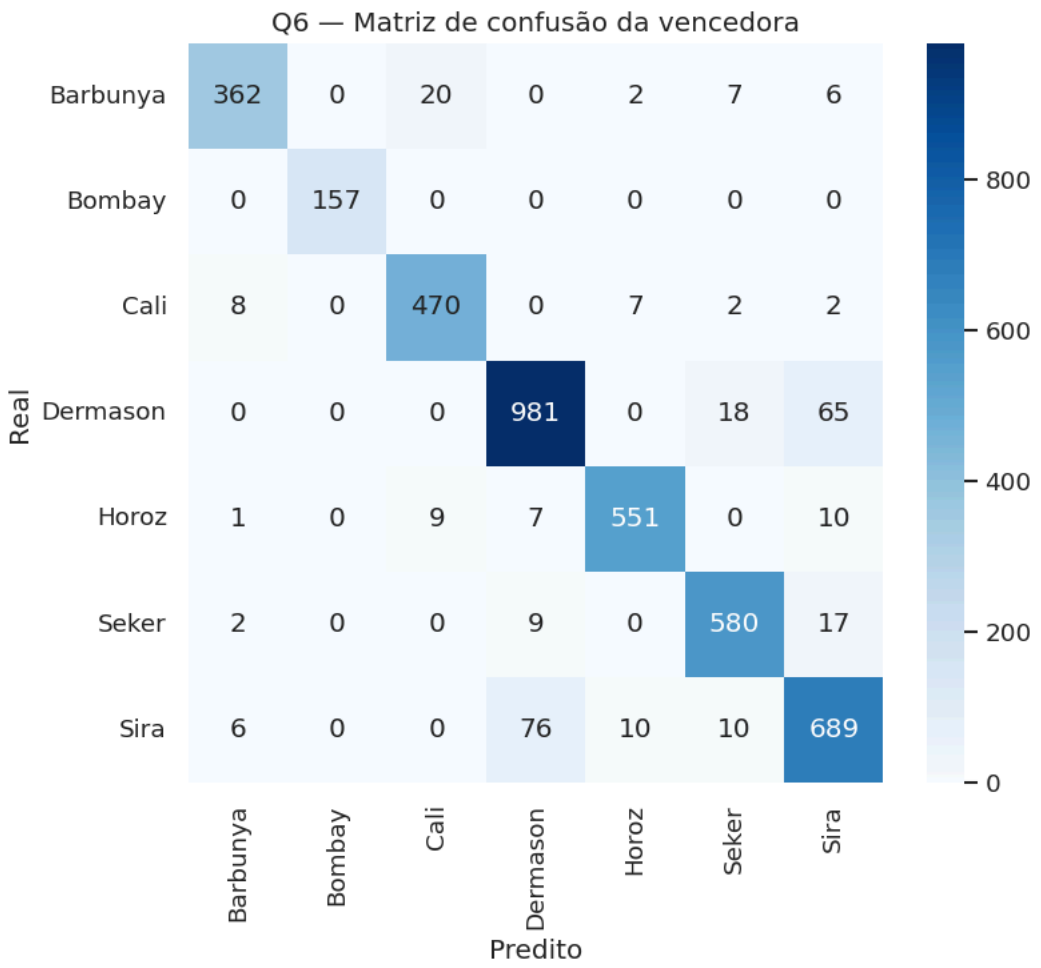


Figura 14 — Matriz de confusão da configuração vencedora (Q6).

Análise. A configuração vencedora foi **1×100**, com macro-F1 de teste 0.9402, weighted-F1 0.9280, acurácia 0.9280 e loss de teste 0.1963. As quatro configurações ficaram muito próximas: a diferença de macro-F1 entre a primeira e a última foi de apenas 0.0008. A 1×40 teve a menor loss de teste (0.1955) e a maior precisão macro (0.9418), mas macro-F1 ligeiramente inferior.

A loss de teste (0.1963) foi superior à de treino (0.1493), e o macro-F1 caiu de 0.9542 no treino para 0.9402 no teste, indicando generalização imperfeita e possível overfitting. A Tabela de classificação por classe mostra que Bombay foi perfeitamente separada (F1 1,000), enquanto Sira (F1 0.8722) e Dermason (F1 0.9181) foram as mais difíceis.

Classificação por classe da vencedora.

class	precision	recall	f1-score	support
Barbunya	0.9551	0.9118	0.9330	397.0000
Bombay	1.0000	1.0000	1.0000	157.0000
Cali	0.9419	0.9611	0.9514	489.0000
Dermason	0.9143	0.9220	0.9181	1064.0000
Horoz	0.9667	0.9533	0.9599	578.0000
Seker	0.9400	0.9539	0.9469	608.0000
Sira	0.8733	0.8710	0.8722	791.0000

Conclusão da Q6. A 1×100 foi selecionada como configuração final. As diferenças entre as topologias são pequenas; a escolha se baseia no macro-F1 de teste, conforme o critério definido.

10. Resultados e discussão — Q7

Configuração. Validação cruzada k=5 estratificada no desenvolvimento de 70% (9.528 exemplos), com a configuração 1×100, lr=0,01, momento=0,9 e regra `low_redundancy` reajustada em cada fold. O teste de 30% não foi usado.

fold	loss_train	acc_train	loss_val	acc_val	macro_f1_val	weighted_f1_val	time_s
0.0000	0.1521	0.9452	0.1959	0.9334	0.9437	0.9334	55.5266

fold	loss_train	acc_train	loss_val	acc_val	macro_f1_val	weighted_f1_val	time_s
1.0000	0.1527	0.9408	0.1910	0.9307	0.9418	0.9311	56.6814
2.0000	0.1550	0.9421	0.1828	0.9270	0.9406	0.9275	53.5523
3.0000	0.1469	0.9459	0.1910	0.9354	0.9482	0.9357	52.2615
4.0000	0.1496	0.9428	0.1804	0.9417	0.9525	0.9417	54.2360

Resumo entre folds.

metric	mean	variance	std	min	max
loss_train	0.151258	0.000010	0.003083	0.146948	0.154964
acc_train	0.943371	0.000005	0.002130	0.940821	0.945946
loss_val	0.188222	0.000041	0.006425	0.180397	0.195908
acc_val	0.933663	0.000030	0.005495	0.927034	0.941732
macro_f1_val	0.945351	0.000024	0.004933	0.940589	0.952475
weighted_f1_val	0.933872	0.000028	0.005326	0.927511	0.941709
precision_macro_val	0.946660	0.000018	0.004197	0.941825	0.952363
recall_macro_val	0.944574	0.000030	0.005515	0.940259	0.952850
epochs	150.000000	0.000000	0.000000	150.000000	150.000000
time_s	54.451551	2.944813	1.716046	52.261496	56.681360

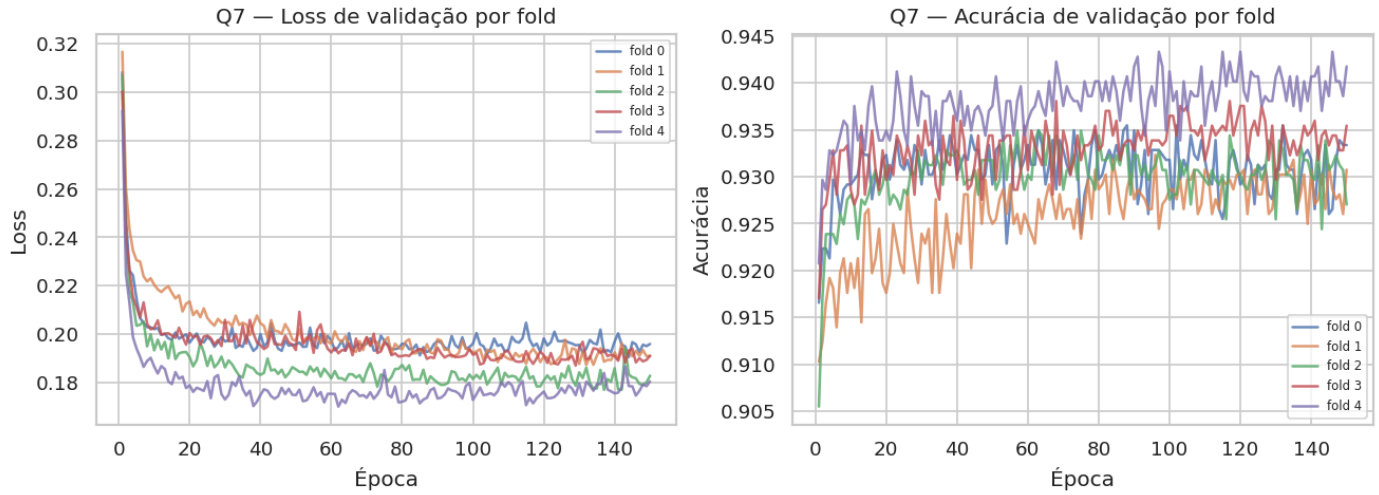


Figura 15 — Curvas de validação por fold (Q7).

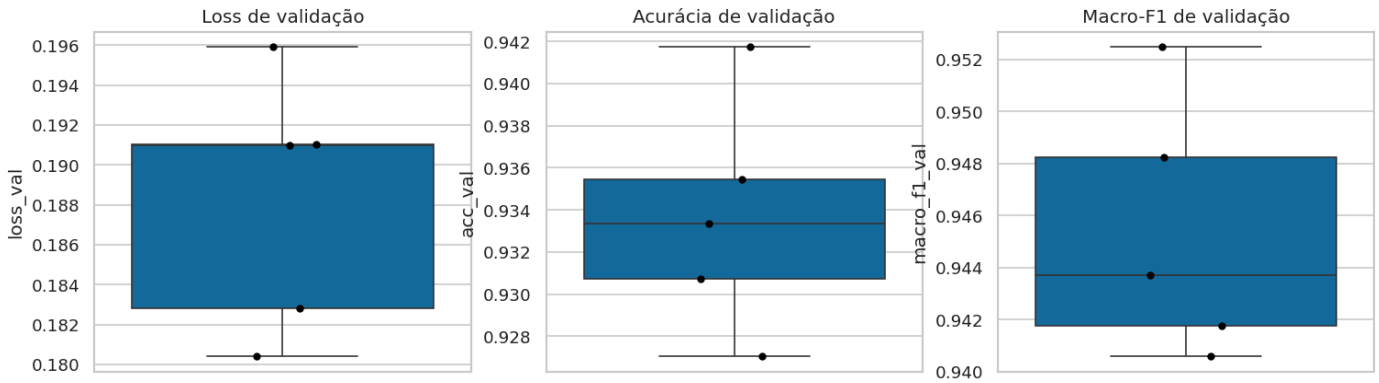


Figura 16 — Distribuição das métricas entre folds (Q7).

Análise. A macro-F1 de validação teve média 0.9454, variância 0.000024 e desvio-padrão 0.0049. A acurácia média foi 0.9337 (variância 0.000030) e a loss média 0.1882 (variância 0.000041). Os folds 0–4 apresentaram macro-F1 de 0.9437, 0.9418, 0.9406, 0.9482, 0.9525.

A variabilidade é pequena, indicando robustez razoável à partição. O fold 2 foi o mais fraco e o fold 4 o melhor; a regra de atributos selecionou 8 features com pequenas variações entre folds, refletindo a estrutura de correlação dos dados. A média da CV (0.9454) ficou acima do resultado da Q6 no teste (0.9402); isso é esperado porque a CV usa o desenvolvimento de 70% e avalia partições de 20%, enquanto a Q6 avalia um holdout de 30% após seleção.

Limitação. A Q6 selecionou a configuração no teste; portanto, a Q7 é uma análise de robustez pós-seleção, não um segundo holdout independente.

Conclusão da Q7. O modelo final é consistente entre partições, com desvio-padrão de aproximadamente 0.005 em macro-F1. A variância baixa sustenta a escolha da configuração 1×100.

11. Conclusão geral

O estudo cumpriu as sete etapas. A Q1 mostrou que a MLP 16-60-7 aprende de forma estável, com baixa sensibilidade à inicialização. A Q2 indicou lr=0,01 e momento=0,9 como a melhor combinação, com macro-F1 de validação 0.9477. A Q3 mostrou que uma única camada oculta é suficiente: as quatro melhores topologias foram 1×60, 1×100, 1×40 e 1×90; redes mais profundas aumentaram tempo e loss de validação. A Q4 evidenciou ganho com mais dados até 100%, com retorno decrescente. A Q5 mostrou que a remoção de redundância reduziu 16 atributos para 8 sem perda relevante de macro-F1. A Q6 selecionou a configuração **1×100** com macro-F1 de teste 0.9402. A Q7 confirmou a robustez, com macro-F1 média 0.9454, variância 0.000024 e desvio-padrão 0.0049.

Configuração final recomendada: uma camada oculta com 100 neurônios, ReLU, Softmax, SGD com lr=0,01 e momento=0,9, batch 32, 8 atributos selecionados pela regra `low_redundancy` e entropia cruzada categórica.

Limitações. (i) No protocolo principal de 150 épocas, nenhuma configuração atingiu a loss de treino de 0,001; o critério foi registrado, mas não satisfeito. O piloto suplementar Q2b (Apêndice B) mostrou que o alvo é atingível com 3×256 e 408 épocas, porém com overfitting e desempenho de teste inferior ao da V1. (ii) Q2–Q6 usaram uma única seed; a estabilidade foi avaliada na Q1 e na Q7. (iii) A Q6 selecionou a vencedora no teste, e a Q7 é uma análise de robustez pós-seleção. (iv) Não foram usados regularização, dropout ou class weights; o desbalanceamento foi tratado apenas via macro-F1 e splits estratificados. (v) Os limiares de correlação (0,95) e de ruído (percentil 10 + mediana) são decisões metodológicas.

Trabalhos futuros. Buscar um equilíbrio entre convergência de treino e generalização, por exemplo com regularização, early stopping na validação e class weights; repetir Q2–Q6 com múltiplas seeds; e usar validação cruzada aninhada para seleção e avaliação totalmente independentes.

Referências

- UCI Machine Learning Repository. **Dry Bean Dataset**, ID 602. Disponível em: https://archive.ics.uci.edu/dataset/602/dry+bean+dataset.
- KOKLU, M.; OZKAN, I. A. Multiclass Classification of Dry Beans Using Computer Vision and Machine Learning Techniques. *Computers and Electronics in Agriculture*, v. 174, 2020.
- TensorFlow/Keras e Scikit-learn: documentação oficial das versões utilizadas.

Apêndice A — consolidado dos vencedores

stage	configuration	selection_metric	value
Q2	lr=0.01; momentum=0.9	macro_f1_val	0.9477
Q3_top1	layers=1; neurons=60	macro_f1_val	0.9477
Q3_top2	layers=1; neurons=100	macro_f1_val	0.9473
Q3_top3	layers=1; neurons=40	macro_f1_val	0.9471
Q3_top4	layers=1; neurons=90	macro_f1_val	0.9470
Q4	fraction=1.0	macro_f1_val	0.9477
Q5	subset=low_redundancy; n_features=8	macro_f1_val	0.9452
Q6	layers=1; neurons=100; lr=0.01; momentum=0.9; features=8	macro_f1_test	0.9402
Q7	k=5; desenvolvimento 70%	macro_f1_val_mean	0.9454

Apêndice B — Piloto de convergência Q2b

Este experimento foi realizado na branch `feat/q2b-convergencia-500ep`, após o congelamento da V1.0.0. Ele não altera as sete questões originais nem o modelo oficial da V1.

Objetivo. Testar se uma rede maior, com até 500 épocas e scheduler, atinge a loss de treino ≤ 0,001. O teste foi usado apenas na avaliação final.

Configuração.

Item	Valor
Topologia	3 camadas × 256 neurônios
Ativações	ReLU / Softmax
Perda	Entropia cruzada categórica
Otimizador	SGD, momentum 0,9
Learning rate	0,01 com `ReduceLROnPlateau` (fator 0,5, paciência 20, mínimo 1e-5)
Batch	32
Dados de treino	70% de desenvolvimento
Teste	30%, apenas na avaliação final
Máximo de épocas	500
Seed	42

Item	Valor
Parâmetros	137.735

Resultado.

Métrica	Valor
Status	Convergiu
Motivo da parada	`target`
Épocas executadas	408
Melhor loss de treino	0,000967 (época 408)
Loss de treino (avaliação)	0,000943
Acurácia de treino	1,0000
Macro-F1 de treino	1,0000
Loss de teste	0,7864
Acurácia de teste	0,9185
Macro-F1 de teste	0,9323
Weighted-F1 de teste	0,9185
Tempo de treino	277,8 s

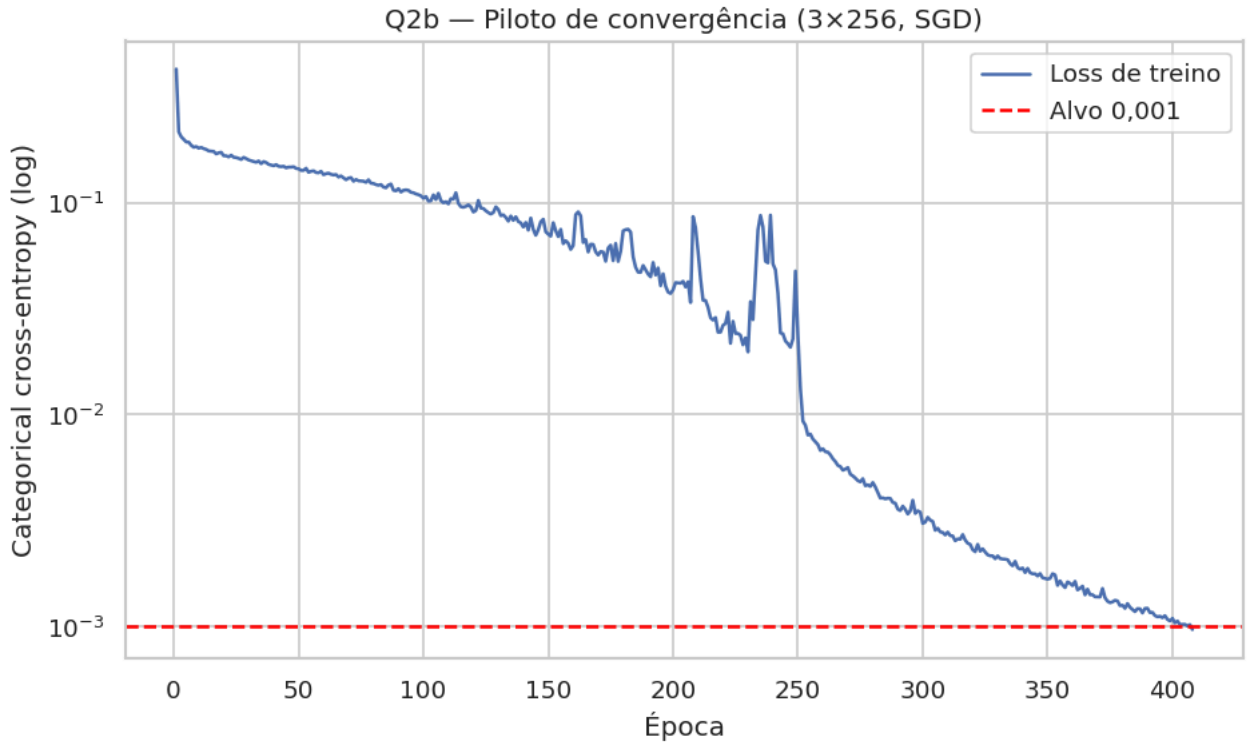


Figura 17 — Loss de treino do piloto Q2b (escala logarítmica) e alvo de 0,001.

Análise. O piloto atingiu o critério de 0,001 na época 408, confirmando que o alvo é viável com uma rede maior e scheduler. O custo foi overfitting acentuado: acurácia e macro-F1 de treino chegaram a 1,0000, enquanto no teste a acurácia foi 0,9185 e o macro-F1 0,9323; a loss de teste subiu para 0,7864. O desempenho de teste ficou abaixo do modelo da V1 (macro-F1 0,9402).

Conclusão. O critério é alcançável, mas não é gratuito: a busca por loss de treino muito baixa sacrificou generalização. Por isso, a V1 permanece como entrega oficial e o Q2b é registrado como evidência suplementar. O relatório detalhado do piloto está em `experiments/q2b_500ep.md`.